2017-2018

Rapport de projet Big Data

M2 MIAGE

Arthur Rozo
19/03/2018

Table des matières

Introduction

Dans le cadre du cours de Big Data, nous avons eu à répondre à certaines questions sur un fichier de données volumineux. Nous avons pu voir lors de ce cours deux technologies basé sur le map reduce pour répondre à ces questions : Hadoop en java, et Spark en scala. Nous étions libres sur le choix de la technologie. J'ai choisi d'utiliser Spark malgré mon manque de connaissance en Scala car cette solution était à la fois plus simple à coder, mais aussi plus rapide à exécuter.

Dans un premier temps, il nous a été demandé de tester nos codes sur un échantillon des données avant de lancer le traitement sur le jeu de données entier. Le jeu de données étant volumineux, nous avions à notre disposition un cluster Spark ou Hadoop suivant la technologie choisie, afin d'exécuter nos traitements de façon efficace.

Ce rapport présente les codes développés, les temps d'exécution ainsi qu'une visualisation des données. A cause d'un problème de droit sur le cluster, je n'ai pas pu exécuter les instructions *saveAsTextFile* qui m'aurait permis de récupérer les données. Les temps d'exécution présent sont donc ceux obtenu lors d'un traitement local des données.

Lien vers les sources :

https://github.com/azoro3/spark_project.git

Question 1

Donnez le classement décroissant des catégories de crime

```
val debut1 = System.currentTimeMillis();
val data =sc.textFile("Z:/Doc/Cours/progDev/Perrin/datamin.csv")
val mappedData =data.map(line => line.split(","))
val selectedData =mappedData.map(line=> (line(5),1))
val reducedData =selectedData.reduceByKey(_+_)
val sortedData =reducedData.sortBy(_._2)
sortedData.saveAsTextFile("Z:/Doc/Cours/progDev/Perrin/out_question1")
Q1:60270 ms
```

Pour répondre à cette question, nous allons splitter les données et ne récupérer uniquement que les catégories de crimes (index 5). Nous allons ensuite ajouter le numéro 1 à la catégorie pour obtenir

Le couple $(catégorie, 1)$.

Nous appliquons ensuite les opérations reduceByKey afin de sommer le nombre de crimes par catégorie de crimes, et l'instruction sortBy afin de trier notre résultat.

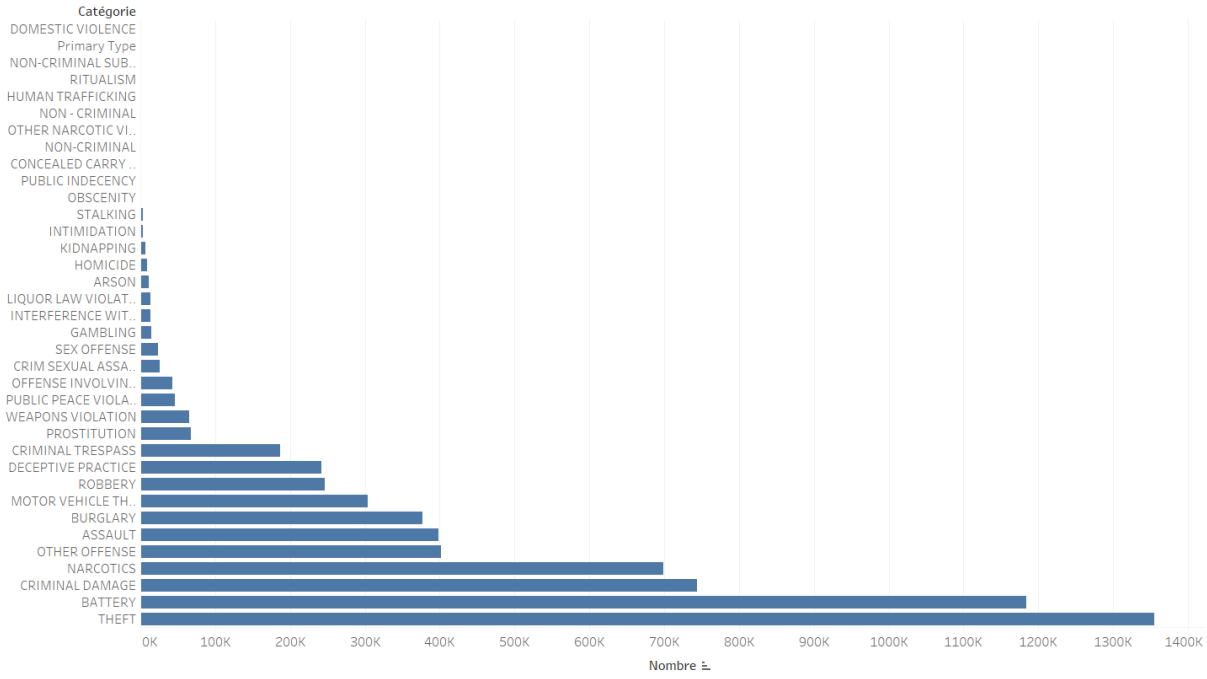

Question 2

Donnez le nombre de crime en fonction de plages horaires

```
val debut2 = System.currentTimeMillis();
val data =sc.textFile("Z:/Doc/Cours/progDev/Perrin/data.csv")
val mappedData =data.map(line => line.split(","))
val selectedData =mappedData.map(line=> line(2))
val pmData =selectedData.filter(line => line.contains("PM"))
val amData =selectedData.filter(line => line.contains("AM"))
val pmData2 =pmData.map(line => line.split(" "))
val amData2= amData.map(line => line.split(" "))
val pmData3= pmData2.map(line => line(1).split(":"))
val amData3= amData2.map(line => line(1).split(":"))
val pmData4 =pmData3.map(line => line(0).toInt+12)
val amData4 =amData3.map(line => line(0).toInt)
val selectedData3 =amData4.union(pmData4)
val data0_4 =selectedData3.filter(line => (line < 5)).map(line
=>("0_4",1)).reduceByKey(_+_)
val data4_8=selectedData3.filter(line => (line < 9 &
line>4)).map(line=>("4_8",1)).reduceByKey(_+_)
val data8_12=selectedData3.filter(line => (line < 13 &
line>8)).map(line=>("8_12",1)).reduceByKey(_+_)
val data12_16=selectedData3.filter(line => (line < 17 &
line>12)).map(line=>("12_16",1)).reduceByKey(_+_)
val data16_20=selectedData3.filter(line => (line < 21 &
line>16)).map(line=>("16_20",1)).reduceByKey(_+_)
val data20_24=selectedData3.filter(line => (line < 25 &
line>20)).map(line=>("20_24",1)).reduceByKey(_+_)
val
data_all=data0_4.union(data4_8).union(data8_12).union(data12_16).union(data16_
20).union(data20_24)
data_all.saveAsTextFile("Z:/Doc/Cours/progDev/Perrin/out_question2")
Q2:75135 m
```

Pour cette question, nous allons récupérer uniquement le primer champ qui contient le jour ou le crime a été commis ainsi que l'heure. Nous allons ensuite récupérer uniquement l'heure du crime, sans les minutes, en faisant attention de bien séparer les heures PM et AM. Nous allons rajouter 12 au heures PM pour les faire correspondre au système français. Une fois cela fait, nous créons un dataset pour chaque plage horaire, sur le même principe que la question précédente. Une fois cela fait, nous allons sommer chaque dataset, pour obtenir le nombre de crimes commis par tranche horaires, et nous concaténons finalement tous les datasets pour obtenir un seul dataset avec la répartition finale.

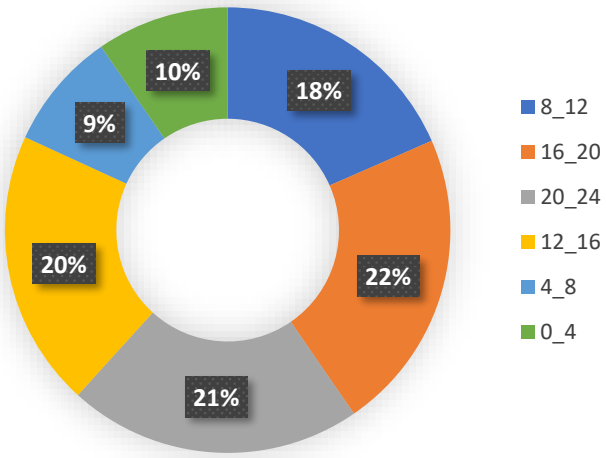
18%
22%
21%
20%
9%
10%
8_12
16_20
20_24
12_16
4_8
0_4

Question 3

Donnez les trois zones les plus dangereuses, et les trois zones les moins dangereuse

```
import org.apache.spark.mllib.clustering.{KMeans, KMeansModel}
import org.apache.spark.mllib.linalg.Vectors
import scala.util.Try
val debut3 = System.currentTimeMillis();
val data =sc.textFile("Z:/Doc/Cours/progDev/Perrin/data.csv")
val cleanData = data.map(line => {
    val splitedLine = line.split(",")
    val splittedArrayLength = splitedLine.length
    (splitedLine(splittedArrayLength-4),splitedLine(splittedArrayLength-3))
    })
val prePreData=cleanData.filter(line =>(!line._1.isEmpty && !line._2.isEmpty
    && Try(line._1.toDouble).isSuccess
    && Try(line._2.toDouble).isSuccess))
val preData = prePreData.map(s => Vectors.dense(s._1.toDouble,
s._2.toDouble)).cache()
val numClusters = 10
val numIterations = 50
val clusters = KMeans.train(preData, numClusters, numIterations)
val WSSSE = clusters.computeCost(preData)
val centers = clusters.clusterCenters
val assignedData = clusters.predict(preData)
val clusterCountDesc = assignedData.map(t => (t, 1)).reduceByKey(_ +
_).sortBy(_._2,false)
val clusterCountAsc = assignedData.map(t => (t, 1)).reduceByKey(_ +
_).sortBy(_._2,true)
val troisP = clusterCountDesc.take(3)
val troisM=clusterCountAsc.take(3)
clusterCountDesc.saveAsTextFile("Z:/Doc/Cours/progDev/Perrin/out_question3_M")
clusterCountAsc.saveAsTextFile("Z:/Doc/Cours/progDev/Perrin/out_question3_P")
Q3:151854 ms
```

Pour cette question, nous allons appliquer l'algorithme K-means afin de clustériser nos données. Nous avons choisi 10 cluster suite à un échange avec notre professeur. Pour cela nous utilisons une librairie la partie machine learning de Spark. Une fois la clusterisation faite, nous récupérons les clusters avant de les trier dans l'ordre croissant et descendant afin de récupérer les 3 plus dangereux et les 3 moins dangereux.

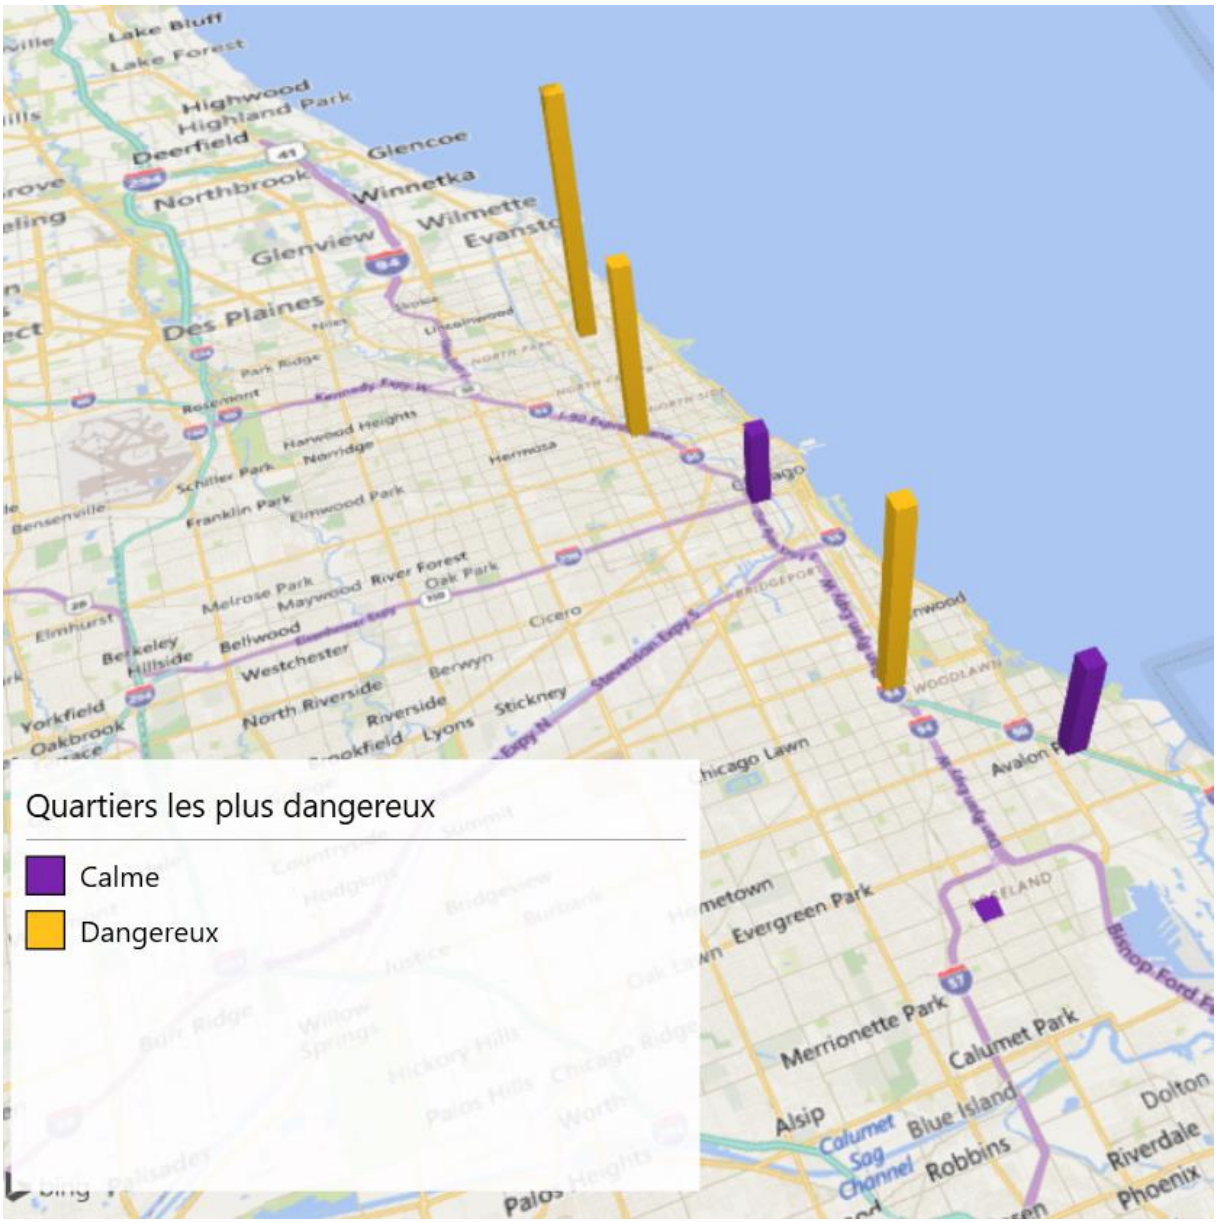
Quartiers les plus dangereux
Calme
Dangereux
Lake Bluff
Lake Forest
Highwood
Highland Park
Deerfield
Glencoe
Northbrook
Winnetka
Wilmette
Glenview
Des Plaines
Park Ridge
Niles
Harwood Heights
Norridge
Schiller Park
Franklin Park
Elmwood Park
Melrose Park
Maywood
River Forest
Oak Park
Elmhurst
Berkeley
Hillside
Bellwood
Westchester
Cicero
North Riverside
Berwyn
Riverside
Stickney
Lyons
Yorkfield
Oakbrook
Chicago Lawn
Evergreen Park
Merrionette Park
Calumet Park
Alsip
Blue Island
Robbins
Dolton
Riverdale
Phoenix
Palos

Question 4

Donnez la répartition des crimes commis

```
val debut4 = System.currentTimeMillis();
val data =sc.textFile("Z:/Doc/Cours/progDev/Perrin/data.csv")
val splittedData = data.map(line => {
    val splitedLine = line.split(",")
    val splittedArrayLength = splitedLine.length
    (splitedLine(splittedArrayLength-15),splitedLine(splittedArrayLength-
4),splitedLine(splittedArrayLength-3))
    })
val filteredData = splittedData.filter(t => (t._1.equals("true")))
val mappedData = filteredData.map(line => (line,1)).reduceByKey(_+_)
mappedData.saveAsTextFile("Z:/Doc/Cours/progDev/Perrin/out_question4")
Q4:55500 ms
```

Dans cette question, nous récupérons l'informations sur la clôture de l'enquête. Nous allons ensuite récupérer les crimes élucidés.

A cause de la volumétrie importantes, il ne m'a pas été possible de proposer une représentation satisfaisante des données. Ci-dessous une répartition des crimes élucidés.

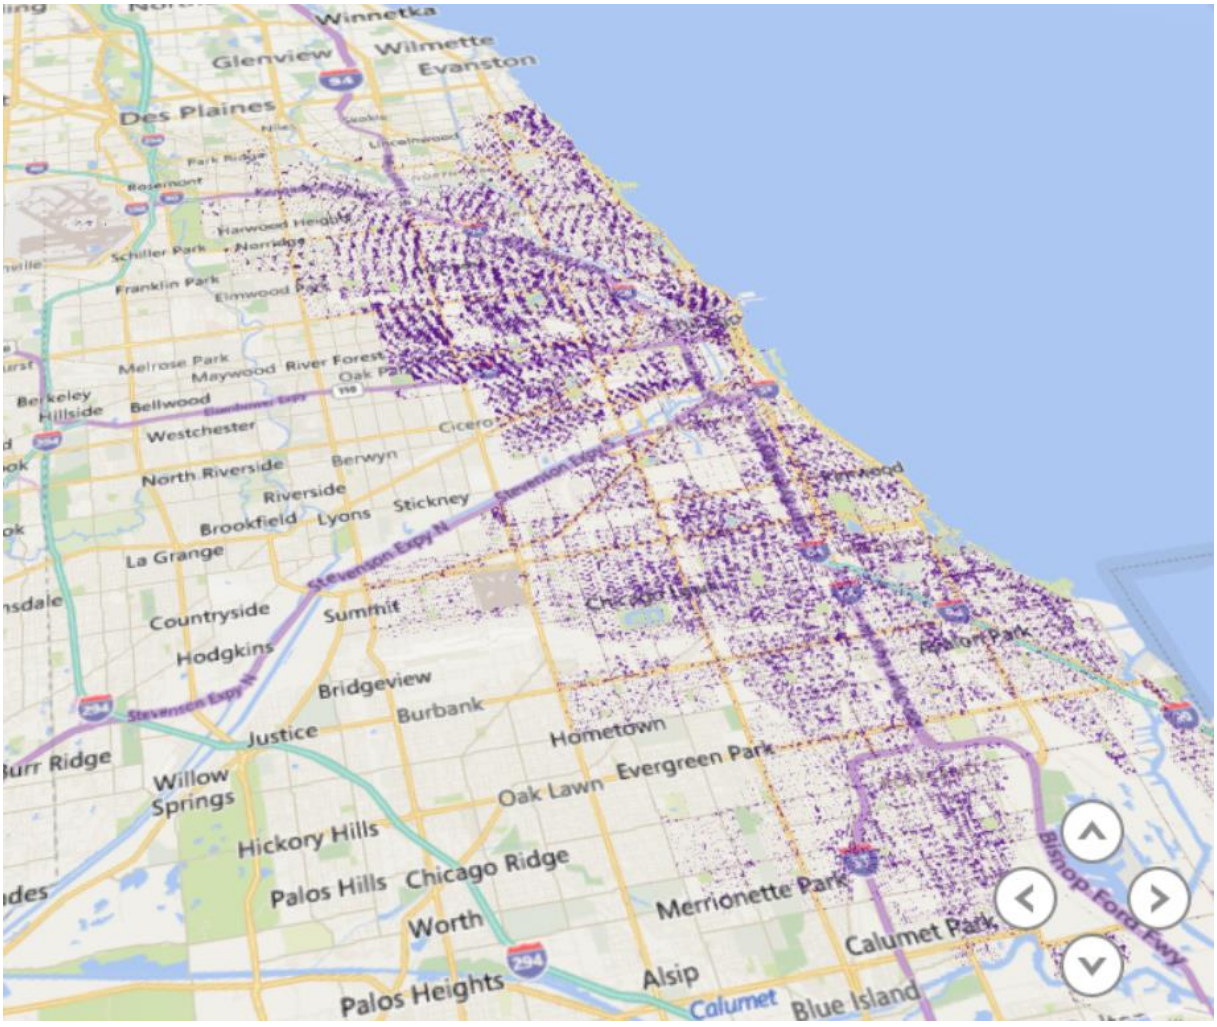

Question 5

Donnez les trois mois les plus dangereux

```
val debut5 = System.currentTimeMillis();
val data =sc.textFile("Z:/Doc/Cours/progDev/Perrin/data.csv")
val mappedData =data.map(line => line.split(","))
val selectedData =mappedData.map(line=> (line(2)))
val mappedData2=selectedData.map(line => line.split(" "))
val selectedData2=mappedData2.map(line=>(line(0)))
val mappedData3=selectedData2.map(line => line.split("/"))
val selectedData3=mappedData3.map(line=>(line(0),1))
val reducedData =selectedData3.reduceByKey(_+_)
val sortedData =reducedData.sortBy(_._2,false)
val res=sortedData.take(3)
sortedData.saveAsTextFile("Z:/Doc/Cours/progDev/Perrin/out_question5")
Q5:8627 ms
```

Pour répondre à cette question, nous récupérons comme pour la question 2 la colonne avec la date du crime, sauf que nous récupérons cette fois le mois du crime. Nous allons ensuite calculer le nombre de crimes dans un mois, trier les données par ordre décroissant, et enfin récupérer uniquement les trois premiers mois.

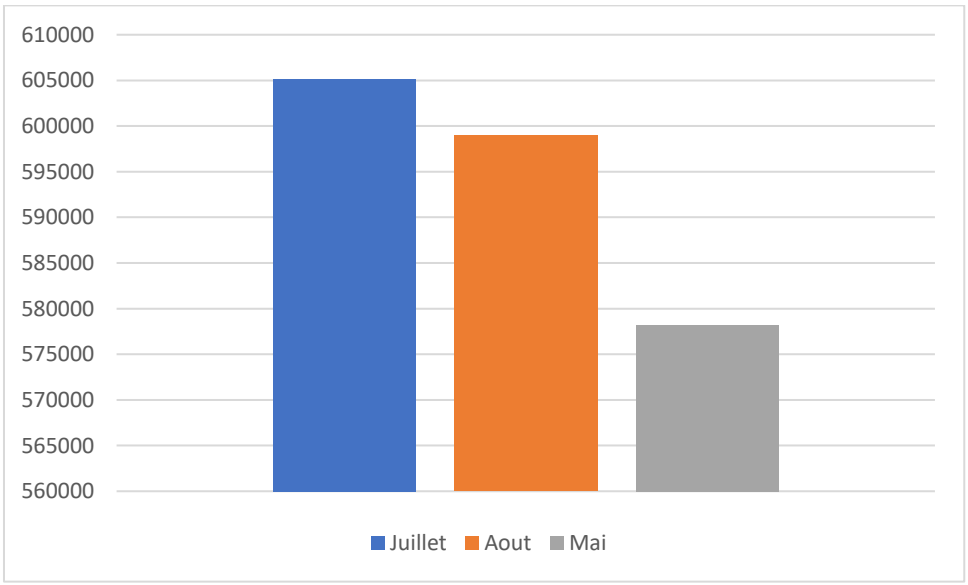

Conclusion

Ce projet nous a permis de mettre en pratique le concept de map reduce, que ce soit en Spark ou en Hadoop. Nous avons aussi eu la chance de pouvoir travailler sur un cluster, et de profiter d'une puissance de calcul que nous ne possédons pas sur nos machines.

Une autre difficulté pour ma part a été d'apprendre un nouveau langage en un temps court. Mais une fois les concepts de la programmation fonctionnelle acquis, Spark a été un réel gain de temps. Certaines opérations qui sont longues et fastidieuses, mais aussi chronophages, sont optimisés en Spark.